

STAGE-AI Metrics: 기업을 위한 생성형 AI 평가지표 설계

STAGE-AI Metrics: Designing Evaluation Metrics for Generative AI in Enterprises

한 수 민 (Sumin Han) 성균관대학교 소프트웨어대학 소프트웨어학과 학부생
김 미 리 (Milee Kim) 성균관대학교 경영대학 경영학과 학부생
유 상 석 (Sangseok You) 성균관대학교 경영대학 경영학과 부교수, 교신저자

요 약

본 연구는 기업의 생성형 AI 도입 과정에서 발생하는 복잡한 리스크를 효과적으로 관리하기 위한 종합적인 평가 프레임워크인 STAGE-AI Metrics를 제안한다. 해당 프레임워크는 사회적 영향(Social impact), 기술적 성능(Technical performance), 조직 내 도입(Adaptation to organization), 지속가능성(Growth in sustainability), 윤리적 고려 사항(Ethical consideration)의 다섯 가지 주요 영역을 포괄하며, 영역별로 세부적인 평가 지표와 관련 벤치마크를 제시한다. 특히 기술적 성능(Technology)을 기반으로 사회적 영향(Social) 및 윤리적 측면(Ethics)을 순차적으로 고려하여 설계되었다. AI 시스템의 기본적인 성능 평가에서 출발, 해당 기술의 도입이 조직과 사회에 미치는 광범위한 파급 효과까지 포괄적으로 평가가 가능하게 하며 추가로 지속가능성(Sustainability)까지 검토할 수 있도록 지원한다. STAGE-AI Metrics는 기존의 단편적인 성능 평가 방식을 넘어, AI 시스템의 기술적 성능뿐만 아니라 사회적 영향과 윤리적 측면까지 고려하는 다면적 접근을 통해 기업이 자사의 특성과 요구사항에 최적화된 AI 모델을 선택하고 도입할 수 있도록 지원한다. 본 연구는 AI 도입의 초기 단계에서 발생할 수 있는 잠재적 문제점들을 사전에 식별하고 대비할 수 있는 실용적인 도구를 제공함으로써, 기업의 AI 도입 성공률을 높이고 장기적인 경쟁력 확보에 기여할 것으로 기대된다.

키워드 : 기업 의사결정, 생성형 AI, 평가지표, 인공지능 도입, 기업용 인공지능

I. 서 론

생성형 AI(Generative Artificial Intelligence; GenAI)

* 이 논문은 2023년 대한민국 교육부와 한국연구재단의
인문사회분야 신진연구지원사업의 지원을 받아
수행된 연구임(NRF-2023S1A5A8081097).

는 등장 이래로 이례적인 실무 자동화와 경쟁력
강화에 대한 기대감을 높이며 많은 기업의 주목을
받았다. 많은 기업이 생성형 AI 도입을 고려하고
있으나, 높은 기대에도 불구하고 제약 사항을 가
진 AI가 실제 업무에 녹아들지 못할 것이라는 우
려로 인해 실질적 도입에 어려움을 겪고 있다. 이

는 고비용 AI 기술을 도입하는 데 기업이 고려해야 할 사항이 매우 복잡적이기 때문이다(Kang *et al.*, 2024).

IDG Korea의 국내 AI 도입 및 활용 현황 조사(IDG Korea, 2023)에 따르면, 90% 이상의 기업이 생성형 AI 도입 검토 단계를 거쳤으나, 40% 이상의 기업이 확정된 도입 계획을 내놓지 못했다. 이는 기업들이 생성형 AI 도입 시 다양한 위험을 우려하기 때문이다.

McKinsey의 조사(McKinsey, 2024)에 따르면, 기업들은 생성형 AI의 정확도와 보안 등의 기술적 신뢰도뿐만 아니라 AI 도입이 동반하는 기업 명성, 윤리, 국가적 보안 등 무형적 영향도 리스크로 인식하고 있다. Apepoint(2024) 또한 기업이 생성형 AI를 도입할 때 데이터 보안, 보유 데이터의 질, 기존 운영 환경과의 통합 복잡성을 우려한다고 밝혔다. 이러한 리스크들은 각기 다른 중요도를 지니며, 이를 완화하기 위한 투자 필요성은 기업의 보수적 태도와 철저한 검증의 필요성을 야기한다.

최근 발표된 유엔(United Nations) 보고서(United Nations, 2024)는 AI 기술의 급속한 발전에 따른 거버넌스와 사회적 영향에 대한 관심이 전 세계적으로 증가하고 있음을 보여준다. 이는 기업이 AI 도입을 고려할 때 기술적 성능뿐만 아니라 윤리적 측면, 특히 고용 구조 변화와 같은 조직 내부의 영향도 함께 고려해야 함을 시사한다. 이러한 추세는 기업의 AI 도입 과정에서 보다 포괄적이고 책임 있는 접근 방식의 필요성을 강조한다.

그러나 이러한 복잡한 리스크를 기업이 종합적으로 검토할 수 있는 수단은 마련되어 있지 않다. 실제로 Gartner(2024)에 따르면, AI 도입에 있어 기업이 마주하는 가장 큰 진입장벽은 생성형 AI의 가치를 정확히 평가할 기준의 부재이다. 현재까지 생성형 AI를 평가하는 연구는 주로 모델 성능 평가에 집중되어 있으며, 이러한 접근은 기업 차원의 다각적인 리스크와 필요성을 충분히 반영하지 못하고 있다.

따라서 본 연구에서는 생성형 AI의 단편적인 성능 평가라는 기존 연구의 한계를 극복하고, 기업 내에서 생성형 AI를 실무 도구로 사용할 때 고려해야 할 요소를 종합적으로 평가하는 평가지표를 제안하고자 한다. 이를 통해 기업이 생성형 AI 도입 시 직면하는 복잡한 리스크를 더욱 효과적으로 관리하고, 기술의 도입과 활용에 대한 신뢰성을 높일 수 있도록 지원하고자 한다.

II. 연구의 배경

인공지능(AI) 기술의 발전은 20세기 중반부터 시작되어 현재까지 지속적으로 이루어져 왔다(Russell *et al.*, 2020). 초기의 AI 연구는 주로 규칙 기반 시스템과 전문가 시스템에 초점이 맞추어져 있었으나, 21세기에 들어서면서 기계학습과 딥러닝 기술의 발전으로 인해 AI의 능력이 급속도로 향상되었다(LeCun *et al.*, 2015).

최근 들어 생성형 AI의 등장이 주목받고 있으며, 이는 AI 기술의 새로운 패러다임을 제시하고 있다(Ramesh *et al.*, 2021). 생성형 AI는 기존의 규칙 기반 예측이나 수치 계산에 중점을 둔 AI 모델과는 달리, 인간과 유사한 고품질의 콘텐츠를 생성할 수 있는 능력을 갖추고 있다(Brown *et al.*, 2020). 이러한 생성형 AI의 발전은 대규모 언어 모델(LLM)과 같은 혁신적인 기술의 등장으로 가속화되었다(Vaswani *et al.*, 2017).

최근 생성형 AI 기술은 급속한 발전을 이루어, 기업의 의사결정 과정에 상당한 영향을 미치고 있다. 2022년 말 ChatGPT의 등장 이후, GPT-4, Claude 2, Gemini, DALL-E 3 등의 고도화된 대규모 언어 모델(Large Language Models, LLMs)이 연이어 공개되었다(McKinsey, 2023). 이러한 생성형 AI 모델들은 텍스트, 이미지, 음성, 비디오 등 다양한 형태의 콘텐츠를 생성할 수 있는 능력을 보여주고 있다. 이러한 발전은 기업의 전략 수립, 리스크 분석, 고객 서비스 개선 등 다양한 영역에서 AI 기반 의사결정 지원 시스템의 도입을 가속

화하고 있다.

이러한 생성형 AI의 능력을 바탕으로 생성형 AI와 인간이 함께 협력한다면, 일 효율 및 생산성을 크게 향상시킬 수 있다(양지훈 외, 2023). Jiang *et al.*(2023)의 연구에서는 패션 디자인 분야에서 인간-AI 협업 시스템인 HAIGEN을 제안하였다. HAIGEN(Human-AI Collaboration for GENeration)은 텍스트-이미지 변환(T2IM), 이미지-스케치 변환(I2SM), 스케치 추천(SRM), 스타일 전이(STM) 등 다양한 생성형 AI 기술을 활용하며, T2IM 모듈은 DALL-E와 유사한 텍스트-이미지 생성 모델을 기반으로 디자이너의 텍스트 설명을 통해 영감 이미지를 생성한다. 해당 시스템은 디자이너의 작업 효율성을 약 250% 향상시켰으며, 작업 품질 또한 개선되었음을 보여주었다. 또한, Jarrahi(2018)의 연구에서는 인간과 AI의 상호보완성을 강조하며, 불확실성, 복잡성, 모호성으로 특징지어지는 조직의 의사결정 과정에서 AI와 인간의 협업이 최적의 결과와 개선된 결과로 이어진다고 서술했다. 생성형 AI와 인간의 협업을 통한 효율성 증대와 기업의 생산성 증대 간의 관계를 규명하기 위한 많은 연구가 진행되고 있다.

약 65%의 기업들이 생성형 AI를 사용한다고 밝혔으며, 기업 관련 응답자의 4분의 3이 향후 몇 년 내에 생성형 AI가 자신들의 산업에 중대하거나 파괴적인 변화를 불러올 것으로 예측한다(Jarrahi, 2018). 그러나 생성형 AI를 실제로 도입할 때는 많은 우려들이 따르며, 관련 연구들이 진행 중이다(이해수, 이모란, 2024). Abbasian *et al.*(2024)의 연구에서는 현재 사용되고 있는 일반적인 평가 지표들이 의료 챗봇 평가에 적합한지에 대한 통일된 기준과 합의가 부족하다고 지적하며, 의료 분야 내 생성형 AI 기반 대화 시스템의 효과성을 평가하기 위한 포괄적인 평가 지표를 제안했다. 그뿐만 아니라, socio-technical 관점으로 AI의 기업 도입을 연구한 Makarius *et al.*(2020)에서는 AI를 조직에 성공적으로 통합하기 위한 사회기술적 프레임워크를 제시했다. 해당 연구들은 AI의 기술적

측면과 아울러 사회적, 조직적 측면을 동시에 고려하는 통합적 접근을 제시함으로써, 생성형 AI의 실질적 사용 및 성공적인 기업 도입을 위해서는 AI 기술의 잠재력을 최대한 활용하면서도 그에 따른 위험을 최소화하는 방법을 모색하는 것이 중요함을 보여준다.

그러나 기존 연구들은 한계점을 지니고 있다. 첫째, 의료 분야와 같은 특정 도메인에만 집중되어 있어 다양한 산업 분야에 적용하기 어렵다. 둘째, 기업의 고유한 특성과 요구사항을 충분히 반영하지 못하고 있다. 셋째, 기업 내 생성형 AI 최초 도입 시의 과정을 고려하기보다, AI를 기업에 도입한 이후의 점진적 프레임워크를 설계하고 분석하는 데 초점을 맞추고 있다. 해당 접근은 생성형 AI 도입의 초기 단계에서 발생할 수 있는 여러 중요한 문제점들을 간과할 수 있다(Malik *et al.*, 2023). AI 도입 전 종합적인 평가가 이루어지지 않으면, 기업의 특정 요구사항과 AI 기술의 적합성을 제대로 판단하기 어려워 부적절한 AI 모델 선택으로 이어질 가능성이 있다. 또한, AI 시스템 구현 초기에 발생할 수 있는 잠재적 리스크를 사전에 식별하고 관리하는 데 어려움을 겪을 수 있어, 기업의 운영, 법적 준수, 윤리적 측면에서 문제를 야기할 수 있다(European Commission, 2023). 사전 평가 없이 AI를 도입하고 나서 점진적으로 개선하는 접근 방식은 초기에 많은 자원을 낭비할 수 있으며, 특히 중소기업이나 자원이 제한된 조직에 큰 부담이 될 수 있다. 그뿐만 아니라, AI 도입 전 조직의 준비도와 문화적 적합성을 평가하지 않으면 도입 후 직원들의 저항이나 기술 수용의 어려움을 겪을 수 있어 생성형 AI의 효과적인 활용을 저해할 수 있다.

따라서 본 연구는 이러한 한계점을 극복하고자 기업에 AI를 도입하기 전에, 사전에 AI 자체를 종합적으로 평가하는 것에 중점을 둔다. 이를 통해 AI 도입의 초기 단계에서 발생할 수 있는 문제점들을 사전에 파악하고 대비할 기회를 제공한다.

III. 평가지표(Metrics) 프레임워크의 도출

본 연구에서는 기업의 생성형 AI 도입을 위한 3단계 평가지표 프레임워크(Metrics Framework)를 제안한다. 이 프레임워크는 기업의 객관적인 모델 선택 기준에 대한 요구를 반영하여 설계되었다. 따라서 오직 AI 모델 자체의 성능, 적응성, 기업 요구사항에 대한 적합성 등을 평가 대상으로 한다. AI의 인터페이스(UI), 사용자 경험(UX), 마케팅 전략, 고객 지원 시스템 등 모델 외적인 비즈니스 측면은 고려되지 않는다. 기업의 데이터나 인프라 역량 또한 기업 내부에서 별도로 평가해야 할 사항으로 간주한다.

모델 평가지표는 기술적 성능, 사회적 영향, 그리고 윤리적 고려 사항이라는 세 가지 핵심 축을 중심으로 구성된다. 이러한 다면적 접근 방식은 AI 시스템의 기본적인 기능성에서부터 광범위한 사회적 파급 효과에 이르기까지 점진적으로 확장되는 평가 기준을 제시한다. Mitchell *et al.*(2019)은 AI 모델의 투명성과 책임성을 높이기 위해 ‘모델 카드(Model Cards)’라는 개념을 도입하여, 모델의 성능뿐만 아니라 의도된 사용 사례, 윤리적 고려 사항, 그리고 잠재적 한계점 등을 포괄적으로 문서화할 것을 제안했다(Mitchell *et al.*, 2019). 이러한 연구는 AI 평가에 있어 기술적 지표를 넘어서는 다차원적 접근의 필요성을 강조한다. 이를 바탕으로 본 연구는 기업이 AI 모델을 도입하고 평가하는 과정에서 이러한 다양한 측면을 체계적으로 고려할 수 있는 실용적인 단계적 평가 프레임워크를 제안한다.

3.1 평가지표 프레임워크 연구 방법론


본 연구에서 제안하는 AI 평가지표는 기술적 성능(Technology)을 기반으로 하여 사회적 영향(Social) 및 윤리적 측면(Ethics)을 순차적으로 고려하도록 설계되었다. 이러한 구조는 AI 시스템의

기본적인 성능 평가에서 출발하여, 해당 기술의 도입이 조직과 사회에 미치는 광범위한 파급 효과까지 포괄적으로 평가하기 위한 것이다.

첫 번째, 기술 단계에서는 CheckList 방법론을 바탕으로 인공지능 모델의 다양한 기술적 특성을 평가한다. CheckList 방법론은 NLP(Natural Language Processing) 모델의 평가를 더욱 체계적으로 수행하기 위한 도구로서, 소프트웨어 엔지니어링의 행동 테스트 개념을 적용하여 설계되었다(Ribeiro *et al.*, 2020). 이러한 방법론은 다양한 언어적 능력과 테스트 유형을 조합한 평가 매트릭스를 제공함으로써, 모델의 성능을 세부적으로 분석하고 일반화 가능성을 더욱 정확하게 검증할 수 있도록 지원한다. 이 방법론은 NLP 모델의 다양한 언어 능력을 체계적으로 평가하는 새로운 접근법을 제시했으며(Ribeiro *et al.*, 2020), 본 연구에서는 이를 확장하여 기업의 AI 도입 시 필요한 포괄적인 성능 평가 프레임워크를 제안한다. 이 프레임워크는 common AI, NLP, 그리고 vision AI 각 영역에 대해 CheckList와 유사한 체계적인 테스트 세트를 포함하며, 다양한 세부 평가 지표를 포함하여 AI 시스템의 실제 성능을 종합적으로 평가할 수 있도록 설계되었다(Sai *et al.*, 2020).

두 번째 단계인 사회적 영향 평가에서는 생성형 AI의 사용자 친화성을 평가한다. 이 단계에서는 주로 해석 가능성과 도메인 일반화 능력을 주요 평가 지표로 삼아, AI 모델의 실제 사용 환경에서의 효과성과 다양한 분야에의 적용 가능성을 평가한다. 마지막 단계인 윤리성 평가에서는 생성형 AI의 데이터 관리와 출력물에 관련된 윤리적 고려 사항을 평가한다. 이 단계는 데이터 관리와 출력물의 두 가지 주요 영역으로 구성되며, 하위 항목으로 데이터 처리 방식, 안전성 및 보안, 그리고 편향성 등을 포함한다.

이러한 단계적 평가 과정을 통해, 기업은 자사에 최적화된 생성형 AI 모델을 선택하고 도입할 수 있다. 본 프레임워크는 기술적 성능뿐만 아니라 사회적, 윤리적 측면까지 고려하며, 기업의 특성과



〈그림 1〉 STAGE-AI Metrics Framework

요구사항에 따라 각 단계의 가중치를 조정할 수 있는 유연성을 제공한다. 추가로, 본 연구에서는 지속가능성을 고려한 추가 단계(Additional Stage)를 제시한다. 이는 필수적인 평가 항목은 아니지만, 기업이 장기적으로 AI를 활용하고자 할 때 고려해야 할 요소들을 포함한다. 여기에는 조직문화의 변화, AI 이용료 변화 추이 등이 포함된다. 이러한 요소들은 AI의 지속적인 활용과 기업 내 성공적인 통합을 위해 중요한 고려 사항이 될 수 있다.

평가지표의 이름은 STAGE-AI Metrics이다. STAGE는 약어로, 사회적 영향(Social impact), 기술적 성능(Technical performance), 조직 내 도입(Adaptation to organization), 지속가능성(Growth in sustainability), 윤리적 고려 사항(Ethical consideration)을 나타낸다(<그림 1>).

IV. STAGE-AI 평가지표 세부내용

평가지표의 세부 내용은 모든 산업군에 포괄적으로 적용할 수 있으면서도 각 기업의 특성을 반

영할 수 있는 하위 평가 지표를 포함한다. 이때, Technical(Stage 1), Social(Stage 2), Ethical(Stage 3), Sustainability(Additional Stage) 크게 4가지 분류 기준을 설정하였으며, 세부 항목은 <표 1>과 같다.

4.1 Stage 1: 기술(Technology)

생성형 AI를 기업 내 의사결정에 이용하기 위해서는 모델 자체의 성능이 우선적으로 보장되어야 한다. 생성형 AI의 결과물이 직접적으로 기업 내 의사결정에 활용되고, 해당 의사결정은 기업의 이윤과 직결되므로, 최종 결과물의 신뢰도를 측정할 수 있는 척도가 필요하다. Zhang *et al.*(2022)의 AI Index 2022 Annual Report에 따르면, 생성형 AI 모델의 성능은 지속적으로 향상되고 있지만, 동시에 그 결과물의 신뢰성 평가가 중요한 과제로 대두되고 있다.

Bommasani *et al.*(2021)은 대규모 언어 모델을 포함한 기초 모델의 기회와 위험을 분석하면서, 이러한 모델들이 기업 의사결정에 활용될 때 신뢰

〈표 1〉 STAGE-AI 세부 하위 항목

Level 0	Level 1Level 0	Level 2
기술(Technology)	공통(Common)	강건성(Robustness)
		다양성(Diversity)
		매개변수의 수(Number of Parameters)
		부동소수점 연산(FLOPs)
	자연어 처리(NLP Task)	간결성(Conciseness)
		근거성(Groundedness)
		최신성(Up-to-dateness)
	비전(Vision Task)	이미지 품질(Image Quality Assessment)
		시각-언어 연동성(Visual Grounding)
		객체 탐지 정확도(Object Detection Accuracy)
사회(Social)	사용자 친화성(User Friendliness)	해석 가능성(Interpretability)
		도메인 일반화(Domain Generalization)
윤리(Ethics)	데이터 관리(Data Governance)	데이터 처리(Data Handling)
	출력물(Output)	안전 및 보안(Safety and Security)
		편향성(Bias)
지속가능성 (Sustainability)	조직문화의 변화 (Shifts in Organizational Culture)	-
	AI 이용료 변화 추이 (Trends in AI Usage Costs)	-

도 문제가 중요하게 다뤄져야 한다고 강조했다. 특히, 신뢰도가 낮은 결과물은 잘못된 의사결정을 초래할 수 있으며, 이는 기업에 심각한 재정적 손실을 초래할 수 있다. 또한, Bender *et al.* (2021)은 대규모 언어 모델의 위험성을 논의하며, 모델의 결과물에 대한 신뢰도 문제를 심도 있게 다루었다. 모델의 크기가 커질수록 결과의 정확성이 항상 비례하여 증가하는 것은 아니며, 때로는 오히려 신뢰할 수 없는 결과를 생성할 수 있다고 경고했다. 이는 모델의 성능 평가 시에는 모델의 크기뿐만 아니라 다양한 요소를 고려해야 함을 보여준다.

그러나 기업의 업종에 따라 사용해야 하는 모델의 종류가 다른 문제점이 존재한다. 예를 들어, 일반 기업의 경우, 업무용 챗봇 등으로 사용 가능한 NLP Model이 적합하다. 반면 제조 기업의 경우, 설계 도면과 같은 실질적인 이미지 출력이 가능한 Vision Model 사용이 적합하다. 이와 같이 기업 특성에 따라 사용 가능한 모델이 다르다고 판단하였

으며, 크게 NLP와 Vision 모델로 분류하였다. 이때, NLP와 Vision 모델은 그 성능을 측정하는 기준이 서로 다른 점이 존재하기 때문에, 모델 성능 측정 지표를 각각 공통부분(Common), NLP Task, Vision Task로 분류하고자 한다. 이를 통해 각 기업의 요구에 맞는 적절한 모델 성능 평가 지표를 제공하여, 보다 신뢰할 수 있는 의사결정을 지원할 것이다.

4.1.1 공통(Common)

해당 평가지표는 NLP 및 Vision 모델 성능 평가 시 공통으로 적용되는 부분이다. 단, 모델 별로 사용되는 벤치마크는 다르게 사용될 수 있다. 이때, 강건성(Robustness), 다양성(Diversity), 매개변수의 수(Number of Parameters), FLOPs를 하위 기준으로 갖는다.

4.1.1.1 강건성(Robustness)

강건성은 모델이 다양한 입력 조건과 환경 변화에 대해 얼마나 안정적으로 성능을 유지하는지를

나타내는 지표이다(Agarwal *et al.*, 2024). 이는 모델이 예상치 못한 입력, 분포 이동, 적대적 공격 등에 대해 얼마나 잘 대응하는지를 평가하며, 모델의 신뢰성, 안전성, 그리고 실제 환경에서의 적용 가능성을 결정하는 핵심 요소이다(Croce *et al.*, 2021). 기업 환경에서는 예측 불가능한 상황이나 노이즈가 있는 데이터에 대해서도 일관된 성능 유지가 중요하게 작용한다. 이를 위해 기존 연구에서 제시된 다양한 벤치마크를 활용해 볼 수 있다. 예를 들어, RobustBench(Croce *et al.*, 2021)는 모델의 적대적 공격에 대한 방어 능력을 평가하기 위해 개발되었으며, 합리적인 계산 예산 내에서 모델의 강건성을 정확하게 측정하는 것을 목표로 한다. 이 외에도 ImageNet-C와 ImageNet-P(Hendrycks *et al.*, 2019), WILDS(Wild Distribution Shift)(Koh *et al.*, 2021), TextFlint(Wang *et al.*, 2021) 등의 벤치마크가 존재한다. 해당 벤치마크들은 각각의 평가 지표를 통해 기업의 AI 시스템이 실제 환경에서 얼마나 안정적으로 작동할 수 있는지를 정량적으로 평가하는 데 활용된다.

4.1.1.2 다양성(Diversity)

다양성은 모델의 다양하고 독창적인 출력물 생성 여부를 평가하는 지표이다(Tevet *et al.*, 2020). 다양성 지표가 높은 모델은 기업 내 의사결정 과정 지원 시 많은 시나리오나 옵션을 생성하고, 특정 유형에 편향되지 않을 가능성이 높다(Zhu *et al.*, 2018). NLP task에서는 모델이 생성한 텍스트 간의 유사도를 계산하여 출력물의 다양성을 측정하는데, Self-BLEU(Zhu *et al.*, 2018)나 Entropy(Zhang *et al.*, 2018) 등이 대표적이다. 이 외에도, Vision task에서는 생성된 이미지 간의 시각적 차이를 수치화하는 LPIPS(Learned Perceptual Image Patch Similarity)(Zhang *et al.*, 2018), MS-SSIM(Multi-Scale Structural Similarity)(Wang *et al.*, 2003) 등이 활용될 수 있다. 해당 벤치마크들은 기업의 AI 시스템이 생성하는 결과물의 독창성과 다양성을 객관적으로 평가하는 기준으로 활용된다.

4.1.1.3 매개변수의 수(Number of Parameters)

모델의 매개변수(파라미터) 수는 해당 모델의 크기와 복잡성을 나타내는 지표이다. 일반적으로 매개변수가 많을수록 모델의 학습 능력과 표현력이 증가하지만, 과적합 위험과 계산 비용도 함께 증가한다. 또한, 많은 파라미터는 모델의 응답 시간을 증가시키기 때문에 실시간 사용성이 떨어질 수 있다는 위험을 지닌다. 따라서 기업은 자사의 요구사항과 자원을 고려하여 적절한 매개변수 수를 가진 모델을 선택해야 한다(He *et al.*, 2016).

4.1.1.4 부동소수점 연산(FLOPs)

FLOPs(Floating Point Operations)은 모델의 연산 복잡도를 측정하는 지표로, 모델의 효율성과 실행 시간을 예측하는 데 사용된다. 보통 낮은 FLOPs 수는 더 빠른 추론 시간과 낮은 계산 비용을 의미해, 기업 내 사용 시 실시간 사용성에 큰 영향을 미친다(Howard *et al.*, 35).

4.1.2 자연어 처리(NLP, Natural Language Processing, Task)

해당 평가지표는 NLP task에 특화된 모델을 측정하기 위한 지표이다. 간결성(Conciseness), 근거성(Groundedness), 최신성(Up-to-dateness)를 기준으로 한다.

4.1.2.1 간결성(Conciseness)

간결성은 모델이 필요한 텍스트 정보를 과도한 상세 설명이나 반복 없이 간단하고 명확하게 전달하는 정도를 평가하는 지표이다(Napoles *et al.*, 2011). 특히 간결성은 중요 정보의 누락을 방지하고, 정보의 양을 줄이는 데에 기여해(Mishra *et al.*, 2014), 의사결정 과정을 가속화하고, 효율적인 의사소통을 촉진해 기업 환경의 효율성을 높일 수 있다. 대표적인 예 중 하나로서 FEQA(Faithfulness Evaluation with Question Answering)(Durmus *et al.*, 2020)는 생성된 텍스트의 사실성과 간결성을 동시에 평가하기 위해 개발된 벤치마크로 자동화된 질의응답 기반 평가를 통해 텍스트의 품질을 측정한다.

다. 이와 유사한 기능을 수행하는 벤치마크로서 REALSumm(Bhandari *et al.*, 2020), EleutherAI Eval (Gao *et al.*, 2022) 등이 있다. 해당 벤치마크들은 각각의 평가 지표를 통해 기업의 AI 시스템이 생성하는 텍스트가 얼마나 효과적으로 핵심 정보를 전달하는지를 정량적으로 평가하는 데 활용된다.

4.1.2.2 근거성(Groundedness)

근거성은 모델이 생성한 텍스트가 주어진 소스 정보나 맥락에 얼마나 충실하고 정확한 기반을 두고 있는지를 평가하는 지표이다(Abbasian *et al.*, 2024). 즉 해당 평가 지표를 통해 생성된 내용이 사실적이고 신뢰할 수 있는지, 맥락에서 벗어나지 않았는지를 알 수 있다. 이는 모델의 신뢰성과 즉결되기 때문에 기업의 의사결정에 직접적으로 쓰기 위해서는 해당 평가지표의 활용이 요구된다. QAGS(Wang *et al.*, 2020)는 질의응답 기반의 평가를 통해 생성된 텍스트의 근거성을 측정하기 위해 개발되었으며, 소스 문서와 생성된 텍스트 간의 사실적 일치도를 평가한다. 이와 유사한 벤치마크로서 DAE(Dependency Arc Entailment)(Goyal *et al.*, 2020), FactCC(Krystinski *et al.*, 2020), SummaC(Laban *et al.*, 2022) 등도 고려해 볼 수 있다. 이러한 벤치마크들은 각각의 평가 지표를 통해 기업의 AI 시스템이 생성하는 내용이 얼마나 신뢰할 수 있고, 사실에 기반하는지를 정량적으로 평가하는 데 활용된다.

4.1.2.3 최신성(Up-to-dateness)

특히 빠르게 변화하는 분야에서 오래된 정보를 제공하는 AI는 사용자에게 잘못된 의사결정을 유도할 수 있어 위험하다. 최신성은 모델이 생성한 정보나 응답이 현재 시점에서 얼마나 최신의 정보를 반영하고 있는지를 평가하는 지표이다(Abbasian *et al.*, 2024). 이는 모델이 학습된 시점 이후의 새로운 사실, 사건, 발전 사항 등을 얼마나 정확하게 포함하고 있는지를 측정한다(Dhingra *et al.*, 2022). 최신성은 AI 시스템의 실용성과 신뢰성에 직접적인 영향을 미친다. 최신성 평가를 위해서는

DyKnow(Mousavi *et al.*, 2024), WikiFact(Petroni *et al.*, 2019)와 같이 동적으로 변화하는 지식을 평가하기 위해 개발된 벤치마크를 활용하여 모델이 시간에 따른 정보 변화를 얼마나 잘 추적하고 반영하는지를 측정해야 한다. 해당 벤치마크들은 각각의 평가 지표를 통해 기업의 AI 시스템이 제공하는 정보가 얼마나 시의적절하고 최신성을 유지하는지를 정량적으로 평가하는 데 활용된다.

4.1.3 비전(Vision Task)

해당 평가지표는 NLP task에 특화된 모델을 측정하기 위한 지표이다. 이미지 품질(Image Quality Assessment), 시각-언어 연동성(Visual Grounding), 객체 탐지 정확도(Object Detection Accuracy)를 기준으로 한다.

4.1.3.1 이미지 품질(Image Quality Assessment)

이미지 품질은 생성된 이미지의 시각적 품질과 완성도를 평가하는 지표이다. 이는 이미지의 선명도, 해상도, 색상 정확도, 노이즈 수준, 그리고 전반적인 미적 품질 등을 포함한다(Zhang *et al.*, 2011). 이미지 품질 평가는 컴퓨터 비전, 이미지 생성 AI, 그리고 이미지 처리 알고리즘의 성능을 측정하는 데 중요한 역할을 한다(Chandler, 2013). 해당 평가 지표는 다양한 응용 분야, 즉 기업 도메인에서 중요하게 다뤄진다. 예를 들어, 엔터테인먼트 산업에서는 사용자 경험과 만족도를 좌우한다(Zhai *et al.*, 2020). 이를 위한 벤치마크의 대표적인 예시로 NIQE(Naturalness Image Quality Evaluator)(Mittal *et al.*, 2012)는 참조 이미지 없이도 자연스러운 이미지의 품질을 평가하는데, 이미지의 자연스러움과 시각적 품질을 객관적으로 측정하는 데 유용하다. 이 외에도 Fully Convolutional Network Score(FCN-Score)(Isola *et al.*, 2017), Realism Score(Kynkäänniemi *et al.*, 2019) 등을 고려해 볼 수 있다. 해당 벤치마크들은 각각의 평가 지표를 통해 기업의 AI 시스템이 생성하는 이미지가 얼마나 높은 품질과 시각적 완성도를 가지는지를 정량적으로 평가하는 데 활용된다.

4.1.3.2 시각-언어 연동성(Visual Grounding)

시각-언어 연동성은 자연어 표현과 이미지 내의 특정 영역을 연결하는 컴퓨터 비전 작업으로, 주어진 텍스트 설명이나 질문에 해당하는 이미지의 특정 부분이나 객체를 정확히 식별하고 위치를 파악하는 능력을 평가하는 지표이다(Zhu *et al.*, 2022). 해당 지표는 컴퓨터 비전과 자연어 처리의 교차점에 위치해 멀티모달 AI 시스템의 핵심 구성 요소로 인식된다. 로봇 공학에서는 자연어 명령을 물리적 환경의 객체와 연결하는 데 사용되는 등(Shridhar *et al.*, 2018), 다양한 응용 분야에서 중요성을 가져 사내 사용 시 영향을 미친다. 이를 위해 자연어 표현에 해당하는 이미지 영역을 정확히 식별하는 능력을 평가하기 위해 개발된 RefCOCO(Yu *et al.*, 2016)를 활용할 수 있다. 이 외에도 Pointing Game(Zhang *et al.*, 2017), Faithful and Plausible Visual Grounding(Reich *et al.*, 2023)를 포함한 벤치마크는 시각-언어 연동의 정확성을 측정하는 데 유용하다. 해당 벤치마크들은 각각의 평가 지표를 통해 기업의 AI 시스템이 텍스트와 이미지 간의 연동을 얼마나 정확하게 수행하는지를 정량적으로 평가하는 데 활용된다.

4.1.3.3 객체 탐지 정확도(Object Detection Accuracy)

객체 탐지 정확도는 컴퓨터 비전 시스템이 이미지나 비디오 내의 객체를 얼마나 정확하게 식별하고 위치를 파악하는지를 평가하는 지표이다(Zhao *et al.*, 2019). 이는 객체의 존재 여부를 판단하는 분류와 객체의 정확한 위치를 특정하는 위치 추정을 모두 포함한다(Liu *et al.*, 2020). 해당 지표는 컴퓨터 비전 모델 평가 시 기초적으로 사용되는 지표이다. FPS(Frames Per Second)(Huang *et al.*, 2017)와 같은 벤치마크는 실시간 객체 탐지 처리 능력을 기반으로 시스템의 처리 속도와 효율성을 측정한다. 이 밖에도 mAP(mean Average Precision)(Padilla *et al.*, 2020), Precision과 Recall(Powers *et al.*, 2020) 등이 대안이다. 해당 벤치마크들은 각각

의 평가 지표를 통해 기업의 AI 시스템이 객체 탐지를 얼마나 정확하고 효율적으로 수행하는지를 정량적으로 평가하는 데 활용된다.

4.2 Stage 2: 사회(Social)

생성형 AI를 기업에 도입해 사내 구성원들과 시너지를 내기 위해서는 사회적 파급력, 즉 사용자 친화성이 핵심적인 요소로 고려되어야 한다. 본 연구에서는 해당 개념을 확장하여, 단순한 인터페이스의 편의성을 넘어 결과물의 이해 가능성과 다양한 비즈니스 도메인에서의 적용 가능성까지 포함하는 광범위한 개념으로 정의한다. 이는 AI 시스템의 성능뿐만 아니라 최종 사용자인 인간의 이해와 활용 능력이 AI 도입의 성공을 좌우한다는 인식에 기반한다.

Makarius *et al.*(2020)의 연구에 따르면, AI와 인간의 성공적인 협업을 위해서는 사회기술적(socio-technical) 관점에서 접근이 필요하다고 강조한다. 이는 기술적 시스템과 사회적 시스템의 상호작용을 고려해야 함을 의미한다. 또한, 사용자 친화적인 AI 시스템은 직원들의 AI 수용도를 높이고, 기업 내 AI 통합 과정을 원활하게 만든다. Wilson과 Daugherty(Wilson *et al.*, 2021)는 AI와 인간의 협업 지능(collaborative intelligence)에 대해 논하며, 사용자 친화적 인터페이스가 AI 시스템의 효과적인 활용에 중요한 역할을 지닌다는 것을 표명했다. 사용하기 어렵거나 복잡한 AI 시스템은 직원들의 저항을 야기할 수 있으며, 이는 결과적으로 AI 도입의 실패로 이어질 수 있다.

결론적으로, AI 시스템의 사용자 친화성은 기업 내 AI 도입 및 활용의 성공을 좌우하는 핵심 요소이다. 사회기술적 관점에서 AI와 인간의 상호작용을 고려하여 설계된 사용자 친화적 시스템은 직원들의 AI 수용도를 높이고, 궁극적으로 AI와 인간의 시너지를 극대화하는 데 기여할 것이다. 이는 단순히 기술적 성능뿐만 아니라, 인적 요소를 함께 고려하는 총체적 접근이 필요함을 시사한다.

4.2.1 사용자 친화성(User-Friendliness)

해당 평가지표는 사용자가 시스템을 사용하는 과정에서 느끼는 편리함과 접근성 정도를 판단하는 지표이다(Heijsters *et al.*, 2023). 본 연구에서는 특히 직접적인 사내 생성형 AI 사용자인 사내 구성원 관점으로 접근하며, Interpretability(해석 가능성), Domain Generalization(도메인 일반화)을 하위 기준으로 한다.

4.2.1.1 해석 가능성(Interpretability)

해석 가능성은 AI 모델이 어떻게 특정 결정이나 예측에 도달했는지를 인간이 이해할 수 있는 방식으로 설명할 수 있는 능력을 의미한다(Doshi-Velez *et al.*, 2017). 이는 AI 시스템의 결과물이 사용자에게 얼마나 명확하고 이해하기 쉬운지를 평가하는 지표이다. 해석 가능성은 AI의 블랙박스 문제를 해결하고, 사용자의 신뢰를 구축하는 데 핵심적인 역할을 한다(Adadi *et al.*, 2018).

해당 평가 지표는 기업 내 생성형 AI 도입 시 중요하게 고려되어야 한다. 기업 환경에서 AI가 제안하는 결정이나 예측의 근거를 이해하는 것은 책임 있는 의사결정을 위해 필수적이다. 궁극적으로 직접적인 사용자인 사내 구성원들이 AI 시스템의 작동 방식을 이해할 수 있을 때, 직원들의 AI 수용도와 활용도를 향상시킬 수 있다(Makarius *et al.*, 2020). LIME(Local Interpretable Model-Agnostic Explanations)(Ribeiro *et al.*, 2016)은 AI 모델의 예측 결과를 설명하기 위한 해석 가능성 평가 벤치마크로, 복잡한 모델의 의사결정 과정을 단순화해 각 특성이 예측에 미치는 영향력을 정량적으로 평가한다. 이 외에도 MATH(Hendrycks *et al.*, 2021), bAbI(Weston *et al.*, 2015) 등이 있다. 해당 벤치마크들은 각각의 평가 지표를 통해 기업의 AI 시스템이 의사결정 과정을 얼마나 투명하고 이해하기 쉽게 설명하는지를 정량적으로 평가하는 데 활용된다.

4.2.1.2 도메인 일반화(Domain Generalization)

도메인 일반화는 AI 모델이 학습한 도메인을

넘어 다른 도메인에서도 효과적으로 작동할 수 있는 능력을 의미하며, 이는 AI 시스템이 새로운 환경이나 상황에 얼마나 잘 적응하고 성능을 유지할 수 있는지를 평가하는 지표이다(Wang *et al.*, 2021). 도메인 간 일반화 능력은 AI 모델의 강건성(robustness)과 적응성(adaptability)을 나타내며, 실사용 상황에서 AI의 실용성을 결정짓는 중요한 요소이다(Zhou *et al.*, 2021).

기업 환경은 다양한 부서, 프로젝트, 그리고 업무 영역을 포함하고 있어, 각각이 서로 다른 도메인으로 간주될 수 있다. AI 시스템이 이러한 다양한 도메인에서 일관된 성능을 보이는 것은 기업의 전반적인 운영 효율성과 의사결정의 일관성을 위해 필수적이다. 또한, 기업이 새로운 시장에 진출하거나 새로운 제품/서비스를 개발할 때, 기존 AI 모델을 큰 수정 없이 적용할 수 있다면 시간과 비용을 크게 절감할 수 있다(Pan *et al.*, 2009). 궁극적으로, 도메인 간 일반화 능력이 뛰어난 AI 시스템은 기업의 변화 대응 능력을 향상시키고, 장기적인 경쟁력을 확보하는 데 기여할 수 있다.

이러한 관점에서, 사용자 측면에서도 해당 지표가 주요하게 작용한다. 사용자들은 다양한 업무 상황에서 동일한 AI 시스템을 일관되게 사용할 수 있어, 생산성을 높일 수 있다. 결과적으로 도메인 간 일반화 능력이 뛰어난 AI 시스템은 기업의 변화 대응 능력을 향상시키고, 장기적인 경쟁력을 확보하는 데 기여할 수 있으며, 동시에 사용자들에게 일관된 경험과 향상된 생산성을 제공함으로써 AI 도입의 성공률을 높일 수 있다. 예를 들어, PACS(Photo, Art, Cartoon, Sketch)(Li *et al.*, 2017)는 다양한 시각적 도메인에서의 일반화 성능을 평가하기 위한 벤치마크이다. 이 외에도 WILDS(Workflows for Interventions on Learning in Diverse Scenarios)(Koh *et al.*, 2021), Meta-Dataset(Triantafyllou *et al.*, 2020) 등이 있는데, 이들은 대체로 사진, 예술 작품, 만화, 스케치와 같은 서로 다른 시각적 스타일에서 AI 모델의 인식 능력을 체계적으로 측정한다. 해당 벤치마크들은 각각의 평가 지표를 통

해 AI 시스템이 얼마나 효과적으로 도메인 간 일반화를 수행하고 실제 환경의 다양한 변화에 적용할 수 있는지를 정량적으로 평가하는 데 활용된다.

4.3 Stage 3: 윤리(Ethics)

AI 기술의 급속한 발전과 함께, 기업이 운영 효율화를 위해 외부에서 개발된 AI 시스템을 도입할 때 윤리적 측면을 주요하게 평가해야 할 필요성이 증가하고 있다. Ayling and Chapman(2022)의 연구에 따르면, AI 시스템의 편향성, 불공정성, 투명성 부족 및 책임성 결여는 윤리적 영향과 예측하기 어려운 결과에 대한 사회 전반에 걸쳐 우려를 야기하고 있다(Ayling *et al.*, 2020). 특히 AI를 구매하여 내부 운영에 활용하는 기업의 경우, 이러한 윤리적 문제가 조직의 의사결정과 직원들의 업무 환경에 직접적인 영향을 미칠 수 있다.

AI 윤리에 관한 관심 증가는 세계 각국과 국제 기구의 대응에서도 확인할 수 있다. 2017년 AI 관련 각종 사고가 발생하면서 AI 개발에 대한 공동 지침인 아실로마 인공지능 원칙(Asilomar AI Principles)이 발표되었다. 이때 윤리 이슈가 언급되면서 AI 윤리 분야의 중요성에 대한 논의가 본격화하기 시작했다(유화선 외, 2024).

Ayling and Chapman(2022)은 AI 윤리와 관련된 39개의 영향 평가 도구를 분석한 결과, “3분의 1이 제3자 공급업체로부터의 AI 시스템 조달 과정에 초점을 맞추고 있다”고 지적한다(Ayling *et al.*, 2020). 이는 AI 제품의 생산자뿐만 아니라 이를 구매하여 배포하는 고객 기업들도 윤리적 평가에 참여해야 할 필요성을 나타낸다.

따라서 AI 도입 과정에서 윤리적 고려 사항을 주요 평가 기준으로 삼는 것은 조직의 건전성 유지와 장기적 기업 가치 증진에 대한 전략적 접근으로 이해될 수 있다. 이러한 맥락에서 기술적 성능과 윤리적 고려 사항 사이의 균형을 찾는 것을 목표로 해야 한다.

4.3.1 데이터 관리(Data Governance)

먼저 AI 모델의 데이터 거버넌스(Data Governance)를 평가한다. 기업의 데이터 처리에 대한 우려가 증대됨에 따라, 이에 관한 체계적인 평가지표의 필요성이 대두되고 있다. 최근 조사에 따르면, 민감한 데이터 사용(58%), 데이터 개인정보 보호(58%), 그리고 데이터 보안(57%)이 주요 우려 사항으로 식별되었다. 이러한 우려로 인해 55%의 기업이 특정 생성형 AI 활용 사례 벤치마킹을 회피하고 있어, 데이터 처리에 대한 객관적 평가 및 관리 체계 구축의 시급성을 시사한다(Deloitte AI Institute, 2024).

4.3.1.1 데이터 처리(Data Handling)

기업 환경에서의 데이터 처리 특성을 고려하여, 데이터 처리 지표는 AI 모델이 운영 과정에서 입력받은 민감한 정보를 어떻게 처리하고 보호하는지 평가한다. 데이터의 수집이나 품질보다는 이미 시스템에 입력된 민감 정보의 안전한 관리와 적절한 사용에 중점을 둔다. ML Privacy Meter(Murakonda and Shokri, 2020)는 기계학습 모델의 학습 데이터 프라이버시 위험을 평가하기 위해 개발된 벤치마크 등을 활용해 평가할 수 있다.

4.3.2 출력물(Output)

AI 출력물(Output)의 윤리성을 평가하며, 특히 AI 모델이 생성한 응답이 윤리적이고 책임 있는 지침을 준수하는 정도에 주목한다. 사내 생성형 AI 사용자의 47%가 생성형 AI로부터 편향된 콘텐츠를 제공받았을 만큼(Applause, 2025) AI 시스템의 출력물에 대한 윤리적 평가의 중요성이 점차 부각되고 있다. 특히 의료, 법률, 금융과 같은 고위험 분야에서는 AI 출력물의 편향성이 심각한 문제를 야기할 수 있어, 출력물의 공정성과 윤리성에 대한 엄격한 평가 기준이 요구된다(Abbasian *et al.*, 2024).

4.3.2.1 안전성과 보안(Safety and Security)

안전성의 경우, LLM이 생성한 유해하거나 부적절한 내용과 관련된 잠재적 위험을 완화하는 데

집중한다. 모델의 답변에 대한 신뢰도, 응답에 포함된 세부 정보의 수준, 답변이 제기할 수 있는 잠재적 위험이나 해악 등 여러 측면을 포함한다. 보안은 정보와 시스템의 기밀성, 무결성 및 가용성을 보장하는 것을 의미한다(Abbasian *et al.*, 2024). 안전성과 보안의 평가를 위해 모델이 생성할 수 있는 유해 콘텐츠를 식별하고 측정하기 위해 개발된 RealToxicityPrompts(Gehman *et al.*, 2020)를 활용할 수 있다. 또한 TruthfulQA(Lin *et al.*, 2021), CivilComments(Borkan *et al.*, 2019), BOLD(Dhamala *et al.*, 2021), BBQ(Parrish *et al.*, 2022) 등도 있다. 해당 벤치마크들은 각각의 평가 지표를 통해 AI 시스템의 안전성과 보안성을 정량적으로 측정하는 데 활용된다.

4.3.2.2 편향성(Bias)

편향성 지표는 AI 모델의 응답에서 나타나는 차별적 처우를 평가한다. 인구통계학적 편향, 대표성 편향 등 다양한 측면의 편향성을 포함한다. CrowS-Pairs(Crowdsourced Stereotype Pairs)(Nangia *et al.*, 2020)는 사회적 편향과 고정관념을 측정하는 데 특화된 벤치마크이다. 이 외에도 WinoGender(Rudinger *et al.*, 2018), BBQ(Parrish *et al.*, 2022), TruthfulQA(Lin *et al.*, 2021), RealToxicityPrompts(Gehman *et al.*, 2020), CivilComments(Borkan *et al.*, 2019) 등의 벤치마크가 존재한다. 해당 벤치마크들은 각각의 평가 지표를 통해 AI 시스템의 공정성을 다각도로 측정하고 개선하는 데 기여한다.

4.4 Additional Stage: 지속가능성(Sustainability)

생성형 AI의 사내 도입은 기업에 혁신적인 기회를 제공하지만, 동시에 장기적인 관점에서 지속가능성을 고려해야 한다. 생성형 AI 기술은 빠르게 진화하고 있으며, 단기적인 성과에만 집중하면 장기적으로 경쟁력을 잃을 수 있다. Teece *et al.*(1997)에 따르면, 기업의 지속적인 성공은 변화하는 환경에 적응하고 혁신할 수 있는 능력에 달려있다. 도입

된 모델의 지속가능한 활용을 고려함으로써, 기업은 기술 변화에 유연하게 대응하고 장기적인 경쟁우위를 유지할 수 있다. 또한, 생성형 AI 도입에는 상당한 초기 투자가 필요하다. AI 기반 프로젝트의 ROI(Return on Investment)는 단기간에 실현되기 어려울 수 있으며, 지속가능성을 고려한 접근은 이러한 투자의 장기적 가치를 극대화하고, 지속적인 혜택을 얻을 수 있게 한다. 추가로 AI 도입으로 인한 조직문화 변화는 불가피해, 이를 장기적인 관점에서 관리할 필요성이 요구된다. Brynjolfsson *et al.*(2017)은 인공지능 시대에 인간과 기계의 협력이 중요하다고 강조했다. 지속가능한 AI 활용은 직원들의 역량을 개발하고, AI와 인간의 시너지를 극대화하는 방향으로 이루어져야 한다.

지속가능성 평가는 AI 도입의 장기적 성공을 위해 필수적이며, 이에 따라 본 연구에서는 지속가능성을 고려한 추가 단계를 제시한다. 해당 단계는 직접적인 평가 요소는 아니지만, 기업이 장기적으로 도입된 생성형 AI를 활용하고자 할 때 고려해야 할 요소들을 포함한다.

4.4.1 조직문화의 변화(Shifts in Organizational Culture)

생성형 AI의 도입은 조직문화에 지대한 영향을 미칠 수 있다. 이는 사내 구성원들의 업무 수행 방식, 역할, 그리고 조직 내 위치에 변화를 불러올 수 있기 때문이다(Brynjolfsson *et al.*, 2017). 먼저, 직원들의 수동성이 증가할 가능성이 높다. 직원들은 사내 생성형 AI의 직접적인 활용자로서, 해당 시스템에 과도하게 의존하면서 직원들이 창의적 사고나 주도적 문제 해결 능력치가 약화할 수 있다(Dergaa *et al.*, 2024). 또한, AI가 복잡한 작업을 반복적으로 대신해, 직원들의 전문성과 기술이 퇴보할 수 있는 우려점도 지닌다(Frey *et al.*, 2017). 이러한 직무 능력 하락과 더불어 AI로 인한 자동화로, AI가 자신들을 대체해 일자리가 사라질 것이라는 고용 불안 두려움을 가지게 될 수 있다(Schrock *et al.*, 2016).

해당 과급력을 고려하지 않고 생성형 AI를 사 내에서 운용하게 되면, 장기적으로 조직의 혁신 능력과 인적 자원의 질이 크게 저하될 우려가 존재한다. 생성형 AI 도입 시 조직문화 변화 관리와 직원 교육은 지속가능한 사내 AI 시스템을 위해 필수적이다.

4.4.2 AI 이용료 변화 추이(Trends in AI Usage Costs)

생성형 AI 사용에는 그 비용이 따르며, 해당 기술의 급격한 발전과 함께 이용료도 변화하고 있다. 생성형 AI의 사내 최초 도입을 위해서는 기본적인 AI 시스템 구축이 요구된다. 해당 시스템 구축을 위해서는 막대한 초기 투자가 필요하며, 이는 기업 규모에 따라 부담이 될 수 있다(Bughin *et al.*, 2017). 또한, 초기 시스템 구축 이후에도 AI 모델의 지속적인 학습과 업데이트, 그리고 대규모 컴퓨팅 자원 사용으로 인해 운영 비용이 지속적으로 발생한다. 그뿐만 아니라, CRN의 보고에 따르면 기업들은 2024년에 단일 최대 생성형 AI 사용 사례에 평균


26억 달러의 비용을 지출하고 있는 만큼(CRN Staff, 2024), 많은 AI 서비스 제공업체들이 수익성 확보를 위해 높은 이용료를 요구하고 있다.

이와 같은 생성형 AI 이용료 증가 추세는 기업의 AI 활용 지속가능성에 직접적인 영향을 미친다. 따라서 지속적이고 안정적인 AI 이용을 위해서는 장기적인 비용-편익 분석이 필수적이다.

V. 평가지표의 적용

인공지능(AI) 모델 평가에 기업의 배경과 특성이 미치는 영향을 고려하여, 기술, 사회적 영향력, 윤리로 구성된 평가 항목에 각각 50%, 30%, 20%의 기본 가중치가 부여되었다. 이러한 기본 가중치 구조는 AI 모델의 다면적 특성을 반영하고자 하였으며, 기술적 성능과 실용적 적용 가능성, 그리고 윤리적 고려 사항의 중요도 차등에 따른 균형을 도모하고자 하였다.

평가의 유연성과 산업별 특수성을 고려하기 위해, 각 기업이 가중치를 $\pm 10\%$ 범위에서 자유롭게



〈그림 2〉 STAGE-AI 적용 예시

조정할 수 있도록 하였다(<그림 2>). 이는 기업의 산업군과 AI 시스템의 적용 업무에 따라 평가 기준의 중요도가 달라질 수 있다는 점을 반영한 것이다. 예를 들어, HR(Human Resources) 분야의 AI 시스템 평가에서는 윤리성의 가중치를 높이고 사용성의 가중치를 낮출 수 있으며, 반대로 IT(Information Technology) 분야에서는 기술력의 가중치를 높이고 윤리성의 가중치를 낮출 수 있다. 이러한 접근 방식을 통해 AI 시스템 평가의 객관성을 유지하면서도, 각 기업과 산업의 특수성을 고려할 수 있는 유연성을 주고자 한다.

5.1 실무자 인터뷰(FGI)를 통한 실효성 평가

5.1.1 인터뷰 방법론

생성형 인공지능의 도입을 고려하거나 이미 활용 중인 국내 IT 기업의 실무 담당자 5명을 대상으로 심층 인터뷰(Focus Group Interview, FGI)를 진행하였다. 특히 각 기업의 생성형 AI 도입 현황과 제약을 구체적으로 파악하고 있는 업무 경력이 있는 전문가들을 중심으로 참여자를 선정하였다.

〈표 2〉 FGI 참여자 세부 사항

참여자	업계	업무 내용	업무 경력
A	게임 산업	플랫폼 전략 개발	10년 이상
B	핀테크(간편 결제) 산업	프로덕트 매니저	20년 이상
C	클라우드 산업	IT 기획	10년 이상
D	완성차 제조 산업	신사업 기획	10년 이상
E	클라우드 산업	기술 영업	4년차

인터뷰 참여자는 위에서 도출된 STAGE-AI 평가지표와 도출 방법을 숙지하고, 평가지표에 관한 생각을 자유롭게 표현하였다. 인터뷰는 준구조화된 심층 면접(semi-structured in-depth interview) 방식을 활용하여, 평가지표가 기업의 AI 도입 의사결정에 도움이 되는 정도, 세부 평가 항목들의 실

무 연관성, 실무 적용 용이성, 그리고 평가지표의 적용 시 기업 상황에 따른 유연성 등에 대해 공통으로 질문하였다. 인터뷰는 대면 및 비대면 형식을 병행하여 평균적으로 1시간 동안 진행되었다. 인터뷰 과정은 모두 녹취하여 분석하였다. 참여자 세부 사항은 <표 2>와 같다.

5.1.2 FGI 시사점

인터뷰 결과, STAGE-AI Metrics는 다양한 평가 항목의 포괄성을 통해 초기 생성형 AI 도입의 정당성을 제시할 수 있다는 점에서 긍정적으로 평가되었다. 특히 조직 특성에 맞춘 가중치 조정 가능성과 같은 요소는 실제 업무에서 중요한 의사결정 기준으로 활용될 수 있음을 시사하였다. 그러나 이러한 포괄성은 동시에 각 기업과 조직의 특수한 업무 환경에 세분화되어 부합하지 못함으로써 실질적 활용성에서 한계를 드러냈다.

한편, AI 도입 시 기업들의 현실적인 고민이 ‘FLOPs’, ‘매개변수의 개수’ 등과 같은 기술적 세부 사항과 비용 효율성 간의 균형에도 있음이 확인되었다. 참여자 C는 이러한 기술적 지표들이 “가격과 직접적으로 연결되어 있다”고 지적했으며, 참여자 E는 “모든 기업이 최고의 AI를 도입할 필요는 없으며, 적정 기술의 선택이 더 중요할 수 있다”고 강조했다. 더불어 참여자 E는 비용 문제와 관련하여 “평가지표가 비용 구조를 분석하는데 도움을 줄 수 있다”고 언급하며, 도입 과정에서 실질적 가치를 제공할 수 있는 도구로 평가하였다. 이는 STAGE-AI Metrics가 기술적 성능과 비용 효율성을 동시에 고려할 수 있는 실용적인 의사결정 도구로 발전할 수 있음을 시사한다. 또한 각 지표에 대한 기업의 규모와 산업적 특성에 따른 차별화된 가중치 부여 방식과의 연결이 요구된다. 이를 바탕으로, 기업의 AI 도입에 있어 최고의 성능을 지닌 AI보다는 도입의 타당성을 충분히 입증할 수 있는 적정 수준의 AI를 선호하는 경향에 부합하는 방향으로의 발전이 가능하다.

구체적으로, STAGE-AI Metrics는 실무에서 활

용할 수 있는 유의미한 기준을 포함하고 있다는 점에서 긍정적 평가를 받았다. 참여자 B는 “평가 지표가 AI의 데이터 보안 신뢰도를 평가하는 데 특히 유용하다”며, 초기 도입 단계에서 해당 지표가 의사결정의 기초 자료로 활용될 수 있음을 강조하였다. 참여자 A 역시 “보안 이슈가 해결되지 않으면 AI 도입 자체가 어려워진다”고 설명하며, 해당 지표의 실질적 유용성을 언급하였다.

또한, STAGE-AI Metrics의 또 다른 강점은 도입부터 운영까지의 전체 프로세스를 아우르는 포괄적인 접근 방식에 있음을 확인할 수 있었다. 참여자 B는 “평가지표가 초기 도입뿐만 아니라 운영 단계에서 발생할 수 있는 거짓 정보 생성, 콘텐츠 검수, 비방 관리 등 실질적인 문제들을 다룬다”고 언급하며, 이러한 요소들이 실제 운영 환경에서 중요한 가치를 제공한다고 평가하였다. 이는 STAGE-AI Metrics가 단순히 기술적 성능을 평가하는 도구를 넘어, 기업이 AI를 안정적으로 운영할 수 있도록 지원하는 실질적 지침 역할을 할 수 있음을 보여준다. 특히, 참여자 D는 “회사 내부 기밀 정보 등의 보안 이슈와 이윤과 즉결된 AI 이용료, 도메인 일반화와 같은 사회윤리와 지속가능성을 포괄적으로 담고 있다”라고 평가했다. 이러한 점은 기업들이 AI 도입 시, 나아가 지속적으로 직면할 수 있는 다양한 리스크를 효과적으로 완화할 수 있는 기반을 제공한다는 점에서 주목할 만하다.

반면, 평가지표의 실무적 적용성을 높이기 위해 구체성과 유연성의 균형을 맞추어야 한다는 의견도 제기되었다. 참여자 C는 “각 task를 중심으로 평가 기준이 세분될 필요가 있다”고 주장하였으며, 지표를 조직별 task나 도메인 특성에 맞게 구체화하고 필요에 따라 지표를 취사선택할 수 있도록 설계해야 한다는 의견을 제시했다.

이러한 맥락에서 기업의 니즈에 따른 평가지표의 세분화가 선행되어야 하며, 특히 각 기업이 자사의 도메인과 업무 특성에 따라 필요한 지표를 선별적으로 활용할 수 있는 유연성이 보장되어야

한다. 리커트 척도 등을 활용한 정량적 평가지표의 개별 측정에서도 각 기업이 자사의 환경과 특성을 고려하여 기존에 운영 중인 평가 체계를 활용하는 것이 바람직하며, 이는 기업의 자율성을 보장하면서도 평가의 실효성을 높일 방안이 될 것이다.

VI. 제언

본 연구는 생성형 AI에 대한 기업의 요구사항을 고려한 평가지표를 개발함으로써 기업 의사결정 최적화를 도모하는 이론적 토대를 마련하였다. 경영학적 관점에서 이러한 평가지표는 기업이 생성형 AI를 효과적으로 도입하고 생산성 증대에 활용하는 데 중요한 근거가 될 수 있다. 이를 바탕으로 향후 기업의 의사결정 과정과 생성형 AI의 융합에 관한 심층적인 연구가 이어질 수 있으며, 이는 경영정보시스템 분야의 발전에 기여할 것으로 기대된다.

또한, 본 연구에서는 AI 도입과 관련된 다양한 관점에서 인터뷰 내용을 분석하였으며, 이를 통해 도출된 결과를 기반으로 한계와 후속 연구의 방향성을 제안하고자 한다. 이는 기업이 AI 도입 과정에서 직면하는 실질적인 문제를 해결하는 데 기여할 뿐만 아니라, 학문적 연구와 실무 간의 간극을 줄이는 데도 중요한 역할을 할 것이다.

실무적 관점에서 본 연구의 평가지표는 기업이 생성형 AI를 실제로 도입하는 과정에 실질적인 도움을 줄 것으로 예상된다. 이 평가지표는 기업의 리더십을 담당하는 경영진부터 실무를 담당하는 직원들까지 생성형 AI에 대한 공통된 이해와 평가 기준을 공유할 수 있게 한다. 이를 통해 조직 전반에 걸친 효과적인 AI 도입과 활용을 촉진할 수 있다.

한편, 본 연구에서 분석된 사례는 기업의 산업군에 초점을 맞추고 있으나, 기업 내 AI가 수행하는 구체적인 과업(task)과 관련된 분석은 상대적으로 깊이 다뤄지지 않았다. 각 기업의 특수성과 과업에 따른 AI의 역할 및 성과는 다를 수 있으므로, 후속 연구에서는 세부 업무(task)에 초점을 맞춰

보다 구체적인 분석이 이루어질 필요가 있다. 이를 통해 AI의 도입 및 평가와 관련된 실질적이고 세부적인 방향성을 제시할 수 있을 것이다.

또한, AI 윤리와 관련하여 본 연구에서 확인된 실무적 요구는 ‘착한 AI’보다 ‘믿을 수 있는 AI’로 나타났으며, 이는 데이터 보안 및 신뢰성이 실무에서 중요한 이슈로 다뤄지고 있음을 시사한다. 이러한 관점은 대중적 윤리와 실무적 요구 사이에서 괴리가 존재할 가능성을 보여주며, 후속 연구에서는 이를 탐구하고 실무와 대중 간의 신뢰를 증진할 방안을 모색해야 할 것이다.

특히, 정량적 평가지표의 한계를 보완하기 위해 ‘최저 기준점’을 설정하는 대안적 접근법 적용이 가능하다. 이는 특정 점수를 경쟁적으로 산출하기보다는 기술적 성과, 사회적 영향, 윤리적 기준 등에서 최소한의 요구사항을 충족하는지를 평가하는 방식이다. 이러한 접근법은 최고 성능의 AI를 도입하는 데 중점을 두기보다는 적절한 수준에서 기업의 실질적인 필요를 충족하는 AI를 도입하려는 기업의 요구를 반영할 수 있다. 이를 기반으로 기업 실무에서 활용할 수 있는 의사결정 지원 도구를 개발하는 것이 후속 연구의 중요한 과제가 될 것이다.

특히 각 기업의 산업군과 조직문화의 차이에서 나타나는 성격 차이에 따라 본 연구에서는 일률적인 가이드라인을 제시하지 않았다. 따라서 기업에서 평가지표를 활용할 때는 각 기업의 성격에 부합하는 보다 구체적인 지표를 적용하는 것이 바람직하다. 이를 통해 기업이 자사의 상황에 맞는 적절한 기준을 설정하고, AI 도입 및 평가의 신뢰성을 높일 수 있을 것이다.

종합하면, 본 연구는 생성형 AI의 기업 도입을 위한 체계적인 평가 프레임워크를 제시함으로써 기업의 혁신적 성장과 경쟁력 강화를 위한 중요한 기반을 마련하였다. 향후 연구에서는 이러한 평가 지표의 실효성을 다양한 맥락에서 검증하고, 산업별 특수성을 반영한 추가적인 평가 항목을 개발함과 동시에 윤리적·사회적 관점에서 AI 도입의 정

당성과 신뢰성을 확보할 방안을 모색해야 할 것이다. 이를 통해 생성형 AI가 기업의 의사결정과 업무 프로세스에 성공적으로 통합되어, 궁극적으로 기업의 혁신과 성장을 촉진할 수 있기를 기대한다.

VII. 결론

본 연구에서 제안한 STAGE-AI Metrics는 기업의 생성형 AI 도입 과정에서 직면하는 다양한 리스크를 종합적으로 평가하고 관리할 수 있는 체계적인 프레임워크를 제시한다.

해당 평가지표는 기술적 성능(Tech)을 기반으로 하여 사회적 영향(Social) 및 윤리적 측면(Ethics)을 순차적으로 고려하여 설계되었으며, 영역별로 구체적인 평가 지표와 벤치마크를 제공함으로써 객관적이고 체계적인 AI 모델 평가를 가능하게 한다. 또한, 생성형 AI 시스템의 기본적인 성능 평가에서 출발하여, 해당 기술의 도입이 조직과 사회에 미치는 광범위한 파급 효과까지 포괄적으로 평가할 수 있도록 했으며, 추가로 지속가능성(Sustainability)까지 검토할 수 있도록 지원한다.

기존의 단편적인 성능 평가를 넘어, 다면적이고 종합적인 평가 체계를 제공하는 한편, 사내 생성형 AI의 도입 초기 단계에서 발생할 수 있는 잠재적 리스크를 사전에 식별하고 관리할 수 있도록 한다. 그뿐만 아니라, 기업의 특성과 요구사항에 따라 평가 지표의 가중치를 조정할 수 있는 유연성을 지닌다.

본 연구는 위에서 언급된 이론 및 실무적 기여와 동시에 분명한 한계도 지니고 있다. 첫째, 본 연구에서 수행한 FGI 참여자의 대표성이다. 인터뷰 참여자는 모두 해당 업무에서 충분한 경력을 보유하고 있으나, 표본 규모가 5명으로 제한되어 다양한 산업군을 대표하는 데에는 한계가 있다. 이러한 점을 고려하여 연구 결과의 해석과 적용에 유의할 필요가 있으며, 향후 연구에서는 더욱 다양한 산업 분야와 기업 규모를 반영한 추가적인 조사가 필요할 것이다.

둘째, 보다 체계적이고 정량적인 방법을 통해 제안된 프레임워크의 유효성 검증이 이루어져야 할 것이다. 특히, 본 연구에서 구체적으로 기술하지 않은 정량적 평가 척도의 개발은 실제 기업 환경에서 실증적 유효성을 검증하는 데 필수적인 역할을 할 것으로 생각한다. 따라서, 후속 연구에서는 프레임워크에서 제시된 개별 항목을 주제로 하여 세부 평가 항목을 개발하거나 및 리커트 척도 등을 활용하여 평가 결과를 데이터베이스화하는 방법도 제안해 볼 수 있다.

또한, AI 기술의 빠른 발전 속도를 고려할 때, 평가 지표와 벤치마크의 지속적인 업데이트와 개선이 요구된다. 따라서 향후 연구에서는 STAGE-AI Metrics를 다양한 산업 분야와 기업 규모에 적용하여 그 효과성을 검증하고, 실제 사용 경험을 바탕으로 프레임워크를 개선해 나가는 것이 필요하다. 또한, AI 기술의 발전에 따른 새로운 윤리적, 사회적 이슈들을 지속적으로 모니터링하고 이를 평가 체계에 반영하는 연구가 진행되어야 할 것이다.

결론적으로, STAGE-AI Metrics는 기업이 생성형 AI를 도입하는 과정에서 직면하는 복잡한 의사결정을 지원하고, 잠재적 리스크를 효과적으로 관리할 수 있는 유용한 도구가 될 것으로 기대된다. 이를 통해 기업은 생성형 AI 기술의 혜택을 최대화하면서도 윤리적이고 책임 있는 사용을 통해 혁신과 성장을 이루어 낼 수 있을 것으로 기대된다.

참 고 문 헌

- [1] 양지훈, 양성병, 윤상혁, “생성형AI 서비스의 성공요인에 대한 탐색적 연구: 텍스트 마이닝과 ChatGPT를 활용하여”, *경영정보학연구*, 제25권, 제2호, 2023, pp. 125-144.
- [2] 유화선, 윤병성, 최희석, “인공지능 윤리(AI Ethics): 인간과 인공지능의 조화로운 공존 방안”, *KISTI 이슈브리프*, 제68권, 2024.
- [3] 이해수, 이모란, “누가 생성형 AI를 이용하는가? : 인구사회학적 변인, 디지털 리터러시, 디지털 전환 인식을 중심으로”, *경영정보학연구*, 제26권, 제3호, 2024, pp. 377-394.
- [4] IDG Korea, “생성형 AI라는 거부할 수 없는 물결”, 2023 국내 AI 도입 및 활용 현황 조사, 2023, Market Pulse.
- [5] Abbasian, M., E. Khatibi, I. Azimi, D. Oniani, Z. Shakeri Hossein Abad, A. Thieme, R. Sriram, Z. Yang, Y. Wang, B. Lin, O. Gevaert, L.-J. Li, R. Jain, and A. M. Rahmani, “Foundation metrics for evaluating effectiveness of healthcare conversations powered by generative AI”, *npj Digital Medicine*, Vol.7, No.82, 2024, pp. 1-12.
- [6] Abbasian, M., E. Khatibi, I. Azimi, D. Oniani, Z. Shakeri Hossein Abad, A. Thieme, R. Sriram, Z. Yang, Y. Wang, B. Lin, O. Gevaert, L.-J. Li, R. Jain, and A. M. Rahmani, “Foundation metrics for evaluating effectiveness of healthcare conversations powered by generative AI”, *npj Digital Medicine*, Vol.7, No.82, 2024.
- [7] Adadi, A. and M. Berrada, “Peeking inside the black-box: A survey on explainable artificial intelligence (XAI)”, *IEEE Access*, Vol.6, 2018, pp. 52138-52160.
- [8] Agarwal, A., S. Kale, and V. Malik, “Machine Learning Robustness: A Primer”, arXiv preprint arXiv:2404.00897, 2024.
- [9] Applause, “Generative AI Use Is Growing - Along With Concerns About Bias”, 2023, Available at: <https://www.applause.com/blog/gen-ai-use-growing-bias-concerns/>.
- [10] AvePoint, “AI & Information Management Report - The Data Problem That’s Stalling AI Success”, 2024.
- [11] Ayling, J. and A. Chapman, “Putting AI ethics to work: Are the tools fit for purpose?”, *AI and Ethics*, Vol.2, No.2, 2022, pp. 405 - 429.
- [12] Bender, E. M., T. Gebru, A. McMillan-Major,

- and S. Shmitchell, “On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?”, *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 2021, pp. 610-623.
- [13] Bhandari, M., P. Gour, A. Ashfaq, P. Liu, and G. Neubig, “Re-evaluating Evaluation in Text Summarization”, In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020, pp. 9347-9359.
- [14] Bommasani, R., D. A. Hudson, E. Adeli, R. Altman, S. Arora, S. von Arx, M. S. Bernstein, J. Bohg, A. Bosselut, E. Brunskill, E. Brynjolfsson, S. Buch, D. Card, R. Castellon, N. Chatterji, A. Chen, K. Creel, J. Q. Davis, D. Demszky, C. Donahue, M. Doumbouya, E. Durmus, S. Ermon, J. Etchemendy, K. Ethayarajh, L. Fei-Fei, C. Finn, T. Gale, L. Gillespie, K. Goel, N. Goodman, S. Grossman, N. Guha, T. Hashimoto, P. Henderson, J. Hewitt, D. E. Ho, J. Hong, K. Hsu, J. Huang, T. Icard, S. Jain, D. Jurafsky, P. Kalluri, S. Karamcheti, G. Keeling, F. Khani, O. Khattab, P. W. Kohd, M. Krass, R. Krishna, R. Kudipudi, A. Kumar, F. Ladhak, M. Lee, T. Lee, J. Leskovec, I. Levent, X. L. Li, X. Li, T. Ma, A. Malik, C. D. Manning, S. P. Mirchandani, E. Mitchell, Z. Munyikwa, S. Nair, A. Narayan, D. Narayanan, B. Newman, A. Nie, J. C. Niebles, H. Nilforoshan, J. Nyarko, G. Ogut, L. Orr, I. Papadimitriou, J. S. Park, C. Piech, E. Portelance, C. Potts, A. Raghunathan, R. Reich, H. Ren, F. Rong, Y. Roohani, C. Ruiz, J. Ryan, C. Ré, D. Sadigh, S. Sagawa, K. Santhanam, A. Shih, K. Srinivasan, A. Tamkin, R. Taori, A. W. Thomas, F. Tramèr, R. E. Wang, W. Wang, B. Wu, J. Wu, Y. Wu, S. M. Xie, M. Yasunaga, J. You, M. Zaharia, M. Zhang, T. Zhang, X. Zhang, Y. Zhang, L. Zheng, K. Zhou, and P. Liang, “On the opportunities and risks of foundation models”, arXiv preprint arXiv:2108.07258, 2021.
- [15] Borkan, D., L. Dixon, J. Sorensen, and N. Thain, “Nuanced metrics for measuring unintended bias with real data for text classification”, *Proceedings of the 2019 World Wide Web Conference*, 2019, pp. 491-500.
- [16] Brown, T. B., B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan, R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei, “Language models are few-shot learners”, *Advances in Neural Information Processing Systems*, Vol.33, 2020, pp. 1877-1901.
- [17] Brynjolfsson, E. and A. McAfee, “The business of artificial intelligence”, *Harvard Business Review*, Vol.7, 2017, pp. 3-11.
- [18] Bughin, J., J. Seong, J. Manyika, M. Chui, and R. Joshi, “Artificial intelligence: The next digital frontier?”, McKinsey Global Institute, 2017.
- [19] Chandler, D. M., “Seven challenges in image quality assessment: past, present, and future research”, *ISRN Signal Processing*, 2013.
- [20] CRN Staff, “GenAI Market Report: 10 Huge ROI, Top Use Cases, AI Costs And Benefits Results”, CRN, 2024, Available at: <https://www.crn.com/news/ai/2024/genai-market-report-10-huge-roi-top-use-cases-ai-costs-and-benefits-results>.
- [21] Croce, F., M. Andriushchenko, V. Schwag, E. Debenedetti, N. Flammarion, M. Chiang, P. Mittal, and M. Hein, “RobustBench: a standardized adversarial robustness benchmark”, arXiv

- preprint arXiv:2010.09670, 2021.
- [22] Deloitte AI Institute, “기업의 생성형AI 사용 현황: 2024년 3분기 보고서”, Deloitte Insights, 2024.
- [23] Dergaa, I., H. Ben Saad, J. M. Glenn, B. Amamou, M. Ben Aissa, N. Guelmami, F. Fekih-Romdhane, and K. Chamari, “From tools to threats: A reflection on the impact of artificial-intelligence chatbots on cognitive health”, *Frontiers in Psychology*, Vol.15, 2024, 1259845.
- [24] Dhamala, J., T. Sun, V. Kumar, S. Krishna, Y. Pruksachatkun, K.-W. Chang, and R. Gupta, “BOLD: Dataset and metrics for measuring biases in open-ended language generation”, *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 2021, pp. 862-872.
- [25] Dhingra, B., J. R. Cole, J. M. Eisenschlos, D. Gillick, J. Eisenstein, and W. W. Cohen, “Time-aware language models as temporal knowledge bases”, *Transactions of the Association for Computational Linguistics*, Vol.10, 2022, pp. 257-273.
- [26] Doshi-Velez, F. and B. Kim, “Towards a rigorous science of interpretable machine learning”, arXiv preprint arXiv:1702.08608, 2017.
- [27] Durmus, E., H. He, and M. Diab, “FEQA: A question answering evaluation framework for faithfulness assessment in abstractive summarization”, In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 5055-5070.
- [28] European Commission, “AI Act | Shaping Europe’s digital future”, 2023, Available at <https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai>.
- [29] Frey, C. B. and M. A. Osborne, “The future of employment: How susceptible are jobs to computerisation?”, *Technological Forecasting and Social Change*, Vol.114, 2017, pp. 254-280.
- [30] Gao, L., J. Tow, S. Biderman, S. Black, A. DiPofi, C. Foster, L. Golding, J. Hsu, K. McDonell, N. Muennighoff, J. Phang, L. Reynolds, E. Tang, A. Thite, B. Wang, K. Wang, and A. Zou, “EleutherAI/lm-evaluation-harness: A framework for few-shot language model evaluation”, GitHub, 2021, Available at <https://github.com/EleutherAI/lm-evaluation-harness>.
- [31] Gartner, “Gartner Survey Finds Generative AI Is Now the Most Frequently Deployed AI Solution in Organizations”, 2024.
- [32] Gehman, S., S. Gururangan, M. Sap, Y. Choi, and N. A. Smith, “RealToxicityPrompts: Evaluating neural toxic degeneration in language models”, *Findings of the Association for Computational Linguistics: EMNLP 2020*, 2020, pp. 3356-3369.
- [33] Goyal, T. and G. Durrett, “Evaluating factuality in generation with dependency-level entailment”, *Findings of the Association for Computational Linguistics: EMNLP 2020*, 2020, pp. 3592-3603.
- [34] He, K., X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition”, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770-778.
- [35] Heijsters, F. A. C. J., G. A. P. van Loon, J. M. M. Santema, M. G. Mullender, M. Bouman, M. C. de Bruijne, and F. van Nassau, “A usability evaluation of the perceived user friendliness, accessibility, and inclusiveness of a chatbot for shared decision making in breast cancer care”, *Journal of Medical Internet Research*, Vol.25, 2023, e46889.
- [36] Hendrycks, D. and T. Dietterich, “Benchmarking neural network robustness to common corruptions and perturbations”, arXiv preprint arXiv:1903.

- 12261, 2019.
- [37] Hendrycks, D., C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, and J. Steinhardt, “Measuring mathematical problem solving with the MATH dataset”, arXiv preprint arXiv:2103.03874, 2021.
- [38] Howard, A. G., M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam, “Mobilenets: Efficient convolutional neural networks for mobile vision applications”, arXiv preprint arXiv:1704.04861, 2017.
- [39] Huang, J., V. Rathod, C. Sun, M. Zhu, A. Korattikara, A. Fathi, I. Fischer, Z. Wojna, Y. Song, S. Guadarrama, and K. Murphy, “Speed/accuracy trade-offs for modern convolutional object detectors”, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017, pp. 7310-7311.
- [40] Isola, P., J. Y. Zhu, T. Zhou, and A. A. Efros, “Image-to-image translation with conditional adversarial networks”, *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017, pp. 1125-1134.
- [41] Jarrahi, M. H., “Artificial intelligence and the future of work: Human-AI symbiosis in organizational decision making”, *Business Horizons*, Vol.61, No.4, 2018, pp. 577-586.
- [42] Jiang, J., D. Wu, H. Deng, Y. Long, W. Tang, X. Li, C. Liu, Z. Jin, W. Zhang, and T. Qi, “HAIGEN: Towards human-AI collaboration for facilitating creativity and style generation in fashion design”, *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2024.
- [43] Kang, H. G., A. Moon, and S. Jeon, “Examining the generative artificial intelligence landscape: Current status and policy strategies”, *Asia Pacific Journal of Information Systems*.
- [44] Koh, P. W., S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao, T. Lee, E. David, D. Stavens, W. Guo, B. Earnshaw, I. Haque, S. M. Beery, J. Leskovec, A. Kundaje, E. Pierson, S. Levine, C. Finn, and P. Liang, “WILDS: A benchmark of in-the-wild distribution shifts”, arXiv preprint arXiv:2012.07421, 2021.
- [45] Kryscinski, W., B. McCann, C. Xiong, and R. Socher, “Evaluating the factual consistency of abstractive text summarization”, arXiv preprint arXiv:1910.12840, 2020.
- [46] Kynkäänniemi, T., T. Karras, S. Laine, J. Lehtinen, and T. Aila, “Improved precision and recall metric for assessing generative models”, *Advances in Neural Information Processing Systems*, Vol.32, 2019.
- [47] LeCun, Y., Y. Bengio, and G. Hinton, “Deep learning”, *Nature*, Vol.521, No.7553, 2015, pp. 436-444.
- [48] Li, D., Y. Yang, Y. Z. Song, and T. M. Hospedales, “Deeper, broader and artier domain generalization”, *Proceedings of the IEEE International Conference on Computer Vision*, 2017.
- [49] Lin, S., J. Hilton, and O. Evans, “TruthfulQA: Measuring how models mimic human falsehoods”, arXiv preprint arXiv:2109.07958, 2021.
- [50] Liu, L., W. Ouyang, X. Wang, P. Fieguth, J. Chen, X. Liu, and M. Pietikäinen, “Deep learning for generic object detection: A survey”, *International Journal of Computer Vision*, Vol.128, No.2, 2020, pp. 261-318.
- [51] Makarius, E. E., D. Mukherjee, J. D. Fox, and A. K. Fox, “Rising with the machines: A socio-technical framework for bringing artificial intelligence into the organization”, *Journal of Business Research*, Vol.120, 2020, pp. 262-273.
- [52] Malik, N., R. Jafar, G. M. Bhat, A. A. Bhat, M. Fayaz, P. Kour, B. A. Lone, A. Raina, S.

- Shafi, S. Manzoor, R. Rasool, B. A. Bhat, R. H. Bhat, N. A. Chowdri, U. Mehraj, S. Nissar, S. S. Qadri, Z. A. Shah, M. A. Siddiqi, H. A. Wani, and M. A. Wani, "Drawbacks of Artificial Intelligence and Their Potential Solutions in Healthcare Sector", *Healthcare*, Vol.11, No.4, 2023, pp. 550.
- [53] McKinsey & Company, "What is generative AI?", McKinsey Digital, 2023, Available at <https://www.mckinsey.com/featured-insights/mckinsey-explorers/what-is-generative-ai>.
- [54] McKinsey, "The state of AI in early 2024: Gen AI adoption spikes and starts to generate value", 2024.
- [55] Mehrabi, N., F. Morstatter, N. Saxena, K. Lerman, and A. Galstyan, "Fairness and bias in artificial intelligence: A brief survey of sources, impacts, and mitigation strategies", *MDPI AI*, Vol.6, No.1, 2024.
- [56] Mishra, R., J. Bian, M. Fiszman, C. R. Weir, S. Jonnalagadda, J. Mostafa, and G. Del Fiol, "Text summarization in the biomedical domain: a systematic review of recent research", *Journal of Biomedical Informatics*, Vol.52, 2014, pp. 457-467.
- [57] Mitchell, M., S. Wu, A. Zaldivar, P. Barnes, L. Vasserman, B. Hutchinson, E. Spitzer, I. D. Raji, and T. Gebru, "Model cards for model reporting", *Proceedings of the Conference on Fairness, Accountability, and Transparency*, 2019, pp. 220-229.
- [58] Mittal, A., R. Soundararajan, and A. C. Bovik, "Making a ",completely blind", image quality analyzer", *IEEE Signal Processing Letters*, Vol.20, No.3, 2012, pp. 209-212.
- [59] Mousavi, S. M., S. Alghisi, and G. Riccardi, "Is Your LLM Outdated? Benchmarking LLMs & Alignment Algorithms for Time-Sensitive Knowledge", arXiv preprint arXiv:2404.08700v1, 2024.
- [60] Murakonda, S. K. and R. Shokri, "ML privacy meter: Aiding regulatory compliance by quantifying the privacy risks of machine learning", arXiv: 2007.09339, 2020.
- [61] Nangia, N., C. Vania, R. Bhalariao, and S. R. Bowman, "CrowS-Pairs: A challenge dataset for measuring social biases in masked language models", *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2020, pp. 1953-1967.
- [62] Napoles, C., B. Van Durme, and C. Callison-Burch, "Evaluating sentence compression: Pitfalls and suggested remedies", *Proceedings of the Workshop on Monolingual Text-To-Text Generation*, 2011, pp. 91-97.
- [63] Padilla, R., S. L. Netto, and E. A. da Silva, "A survey on performance metrics for object-detection algorithms", *2020 International Conference on Systems, Signals and Image Processing (IWSSIP)*, IEEE, 2020, pp. 237-242.
- [64] Pan, S. J. and Q. Yang, "A survey on transfer learning", *IEEE Transactions on Knowledge and Data Engineering*, Vol.22, No.10, 2009, pp. 1345-1359.
- [65] Parrish, A., N. Nangia, A. Padmakumar, V. Khetan, P. Jain, S. Sharma, A. Nenkova, H. Joshi, R. Chen, Y. Bisk, C. Callison-Burch, and R. Rudinger, "BBQ: A hand-built bias benchmark for question answering", *Findings of the Association for Computational Linguistics: ACL 2022*, 2022, pp. 2086-2105.
- [66] Petroni, F., T. Rocktäschel, P. Lewis, A. Bakhtin, Y. Wu, A. Miller, and S. Riedel, "Language models as knowledge bases?", arXiv:1909.01066, 2019.
- [67] Powers, D. M., "Evaluation: From precision, re-

- call and F-measure to ROC, informedness, markedness and correlation”, arXiv preprint arXiv:2010.16061, 2020.
- [68] Ramesh, A., M. Pavlov, G. Goh, S. Gray, C. Voss, A. Radford, M. Chen, and I. Sutskever, “Zero-shot text-to-image generation”, *Proceedings of the 38th International Conference on Machine Learning*, PMLR 139, 2021, pp. 8821-8831.
- [69] Reich, D., F. Putze, and T. Schultz, “Measuring faithful and plausible visual grounding in VQA”, arXiv preprint arXiv:2305.15015, 2023.
- [70] Ribeiro, M. T., T. Wu, C. Guestrin, and S. Singh, “Beyond accuracy: Behavioral testing of NLP models with CheckList”, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020, pp. 4902-4912.
- [71] Ribeiro, M. T., S. Singh, and C. Guestrin, ““Why should I trust you?”: Explaining the predictions of any classifier”, *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [72] Rudinger, R., J. Naradowsky, B. Leonard, and B. Van Durme, “Gender bias in coreference resolution”, *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, Vol. 2 (Short Papers), 2018, pp. 8-14.
- [73] Russell, S. J. and P. Norvig, *Artificial Intelligence: A Modern Approach* (4th ed.), Pearson, 2024.
- [74] Sai, A. B., A. K. Mohankumar, and M. M. Khapra, “A Survey of Evaluation Metrics Used for NLG Systems”, arXiv preprint arXiv:2008.12009, 2020.
- [75] Schrock, W. A., D. E. Hughes, F. Q. Fu, K. A. Richards, and E. Jones, “Better together: Trait competitiveness and competitive psychological climate as antecedents of salesperson organizational commitment and sales performance”, *Marketing Letters*, Vol.27, No.2, 2016, pp. 351-360.
- [76] Shridhar, M. and D. Hsu, “Interactive visual grounding of referring expressions for human-robot interaction”, *Robotics: Science and Systems*, 2018.
- [77] Teece, D. J., G. Pisano, and A. Shuen, “Dynamic capabilities and strategic management”, *Strategic Management Journal*, Vol.18, No.7, 1997, pp. 509-533.
- [78] Tevet, G. and J. Berant, “Evaluating the Evaluation of Diversity in Natural Language Generation”, arXiv preprint arXiv:2004.02990, 2020.
- [79] Triantafillou, E., T. Zhu, V. Dumoulin, P. Lamblin, U. Evci, K. Xu, R. Goroshin, C. Gelada, K. Swersky, P.-A. Manzagol, and H. Larochelle, “Meta-dataset: A dataset of datasets for learning to learn from few examples”, *International Conference on Learning Representations*, 2020.
- [80] United Nations, “Report of the High Level Advisory Body on AI”, 2024.
- [81] Vaswani, A., N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need”, *Advances in Neural Information Processing Systems*, Vol.30, 2017.
- [82] Wang, A., K. Cho, and M. Lewis, “Asking and answering questions to evaluate the factual consistency of summaries”, arXiv preprint arXiv:2004.04228, 2020.
- [83] Wang, J., C. Lan, C. Liu, Y. Ouyang, T. Qin, W. Lu, Y. Chen, W. Zeng, and P. S. Yu, “Generalizing to unseen domains: A survey on domain generalization”, *IEEE Transactions on Knowledge and Data Engineering*, Vol.35, No.8, 2023, pp. 8052-8072.

- [84] Wang, T., X. Wan, H. Jin, Z. Liu, Y. Ren, W. Zhou, J. Guo, Y. Xiang, Y. Zhang, and X. Zhu, "TextFlint: Unified Multilingual Robustness Evaluation Toolkit for Natural Language Processing", arXiv preprint arXiv:2103.11441, 2021.
- [85] Wang, Z., E. P. Simoncelli, and A. C. Bovik, "Multiscale structural similarity for image quality assessment", *The Thirty-Seventh Asilomar Conference on Signals, Systems & Computers*, 2003, Vol.2, pp. 1398-1402.
- [86] Weston, J., A. Bordes, S. Chopra, A. M. Rush, B. van Merriënboer, A. Joulin, and T. Mikolov, "Towards AI-complete question answering: A set of prerequisite toy tasks", arXiv preprint arXiv:1502.05698, 2015.
- [87] Wilson, H. J. and P. R. Daugherty, "Collaborative intelligence: Humans and AI are joining forces", *Harvard Business Review Special Issue*, Winter 2021.
- [88] Yu, L., P. Poirson, S. Yang, A. C. Berg, and T. L. Berg, "Modeling context in referring expressions", in *European Conference on Computer Vision*, Springer, Cham, 2016, pp. 69-85.
- [89] Zhai, G. and X. Min, "Perceptual image quality assessment: a survey", *Science China Information Sciences*, Vol.63, No.11, 2020, pp. 1-52.
- [90] Zhang, D., S. Mishra, E. Brynjolfsson, J. Etchemendy, D. Ganguli, B. Grosz, T. Lyons, J. Manyika, J. C. Niebles, M. Sellitto, Y. Shoham, J. Clark, and R. Perrault, "The AI Index 2022 Annual Report", arXiv preprint arXiv:2205.03468, 2022.
- [91] Zhang, J., S. A. Bargal, Z. Lin, J. Brandt, X. Shen, and S. Sclaroff, "Top-down neural attention by excitation backprop", *International Journal of Computer Vision*, Vol.126, No.10, 2017, pp. 1084-1102.
- [92] Zhang, L., L. Zhang, X. Mou, and D. Zhang, "FSIM: A feature similarity index for image quality assessment", *IEEE transactions on Image Processing*, Vol.20, No.8, 2011, pp. 2378-2386.
- [93] Zhang, R., P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric", *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018, pp. 586-595.
- [94] Zhang, Y., M. Galley, J. Gao, Z. Gan, X. Li, C. Brockett, and B. Dolan, "Generating informative and diverse conversational responses via adversarial information maximization", arXiv preprint arXiv:1809.05972, 2018.
- [95] Zhao, Z. Q., P. Zheng, S. T. Xu, and X. Wu, "Object detection with deep learning: A review", *IEEE Transactions on Neural Networks and Learning Systems*, Vol.30, No.11, 2019, pp. 3212-3232.
- [96] Zhou, K., Z. Liu, Y. Qiao, T. Xiang, and C. C. Loy, "Domain generalization: A survey", *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2021.
- [97] Zhu, C., Y. Zhou, Y. Shen, G. Luo, X. Pan, M. Lin, C. Chen, L. Cao, X. Sun, and R. Ji, "SeqTR: A simple yet universal network for visual grounding", *European Conference on Computer Vision*, 2022.
- [98] Zhu, Y., S. Lu, L. Zheng, J. Guo, W. Zhang, J. Wang, and Y. Yu, "Texygen: A benchmarking platform for text generation models", *The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*, 2018, pp. 1097-1100.

STAGE-AI Metrics: Designing Evaluation Metrics for Generative AI in Enterprises

Sumin Han* · Milee Kim** · Sangseok You***

Abstract

This study proposes STAGE-AI Metrics, a comprehensive evaluation framework designed to effectively manage the complex risks associated with the adoption of generative AI in enterprises. The framework encompasses five key dimensions: Social Impact, Technical Performance, Adaptation to Organization, Growth in Sustainability, and Ethical Consideration. For each dimension, it provides detailed evaluation metrics and relevant benchmarks. Notably, the framework is structured in a sequential manner, first assessing Technical Performance (Technology) as the foundation, followed by Social Impact (Social) and Ethical Considerations (Ethics) to ensure a holistic evaluation.

STAGE-AI Metrics enables a comprehensive assessment that extends beyond the fundamental evaluation of AI system performance to include its broader impact on organizations and society, while also considering sustainability (Sustainability) as a critical factor. Unlike conventional performance assessment methods that focus solely on technical aspects, this framework adopts a multi-dimensional approach, integrating social and ethical perspectives. This allows enterprises to select and implement AI models that are optimized for their unique characteristics and requirements.

By providing a practical tool to identify and mitigate potential issues in the early stages of AI adoption, this study aims to enhance the success rate of AI implementation in enterprises and contribute to their long-term competitiveness.

Keywords: *Corporate Decision-Making, Generative AI, Evaluation Metrics, AI Adoption, Enterprise AI*

* Undergraduate Student, Computer Science and Engineering, Sungkyunkwan University

** Undergraduate Student, Professor, Business Administration, Sungkyunkwan University


*** Corresponding Author, Associate Professor, Business Administration, Sungkyunkwan University

● 저 자 소 개 ●



한 수 민 (hyhsumin728@g.skku.edu)

성균관대학교 소프트웨어대학 소프트웨어학과 학사학위 과정 중에 있다. 주요 관심 분야는 인공지능, 시스템, 법이다. 특히, 네트워크 시스템, Vision과 NLP를 포함한 생성형 AI, 비즈니스 AI 응용, 풀스택 개발 등을 중심으로 AI 기술의 실제 비즈니스 적용과 시스템 최적화 연구에 집중하고 있다.



김 미 리 (yjhs00@g.skku.edu)

경영대학 경영학과 학사학위 과정 중에 있다. 주요 관심 분야는 경영 정보이다. 주요 연구 관심 분야는 대규모 언어 모델(LLM)을 포함한 생성형 AI, 디지털 전환, 기술-인간 상호작용, 전략 컨설팅 등이며, 특히 AI 기술의 기업 및 산업 현장 적용과 관련된 연구에 집중하고 있다.



유 상 석 (sangyou@skku.edu)

성균관대학교 경영대학에서 경영정보시스템 전공 부교수로 재직 중이다. 미시간 대학교에서 박사학위를 취득하고, 프랑스의 HEC Paris에서 조교수로 근무하였다. 주요 연구 분야는 인간-로봇 상호작용 및 서비스 개발, 인공지능을 이용한 의사결정 및 상호작용, 오픈소스소프트웨어 개발 등이다.

논문접수일 : 2024년 12월 31일

게재확정일 : 2025년 02월 04일

1차 수정일 : 2025년 02월 03일